Lezione 2

Regressione

Paolo Bosetti

Indice

1 Regressione lineare **1**
1.1 Modello lineare univariato 1
1.2 Estrapolazione 13
1.3 Regressione ai minimi quadrati 17
1.4 Regressione lineare generalizzata 22
1.4.1 Soluzione 28

1 Regressione lineare

1.1 Modello lineare univariato

Supponiamo di avere una relazione tra due variabili x e y del tipo:

$$y = a + bx + cx^2$$

Realizziamo un esperimento che ci consenta di scegliere i valori di x e misurare i corrispondenti valori di y.

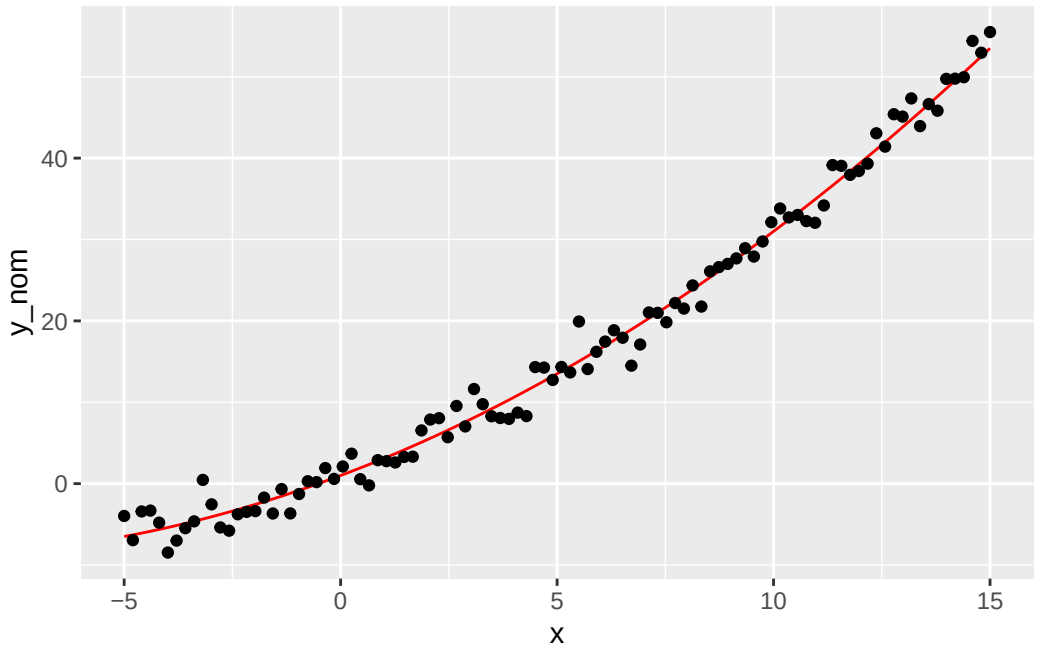
Cominciamo con il simulare l'esperimento, generando dei dati sintetici. In particolare, generiamo 100 valori di x equispaziati tra -10 e 10, e calcoliamo i corrispondenti valori di y secondo la relazione sopra (`y_nom`, valore *nominale*), aggiungendo un po' di rumore casuale normale con media nulla e deviazione standard 2 (`y`, valore *misurato*).

```
set.seed(0)
N <- 100
a <- 1
b <- 2
c <- 0.1

df <- tibble(
```

```r
  x = seq(-5, 15, length.out=N),
  y_nom = a + b*x + c*x^2,
  y = y_nom + rnorm(N, 0, 2)
)

# in rosso la relazione nominale, in nero le "misure"
df %>% ggplot(aes(x=x)) +
  geom_line(aes(y=y_nom), color="red") +
  geom_point(aes(y=y))
```



Il nostro obiettivo è stimare i parametri a, b e c a partire dai dati osservati.

Il primo passo è definire un **modello statistico** che corrisponda alla relazione $y = f(x)$ ma includa anche il disturbo casuale:

$$y_i = a + bx_i + cx_i^2 + \epsilon_i, \quad \epsilon_i \sim N(0, \sigma^2)$$

Si noti che il modello si dice **lineare** perché è lineare nei **parametri** a, b e c, anche se non è lineare nella variabile x.

In R, il primo passo è trasformare il modello in una formula. La regola generica è:

> **!** Regole per scrivere una formula in R
>
> - L'uguale si rimpiazza con il simbolo `~`.
> - Gli oggetti a sinistra del simbolo `~` rappresentano la **variabile dipendente** (in

questo caso y).

- Gli oggetti a destra del simbolo `~` rappresentano le **variabili indipendenti**, o *predittori* (in questo caso x, x^2, x^3, ecc.), separati da `+` ed eliminando i coefficienti (in questo caso a, b, c) che saranno stimati dal modello.
- L'**intercetta** (il termine a) è implicita e non va scritta nella formula. Se si vuole un modello **senza** intercetta, bisogna aggiungere `- 1` alla formula.
- I residui non vanno scritti nella formula, ma sono impliciti nel modello.

La formula va poi passata come primo argomento alla funzione `lm()` (*linear model*) che calcola i parametri del modello. Il secondo argomento della funzione è il dataset che contiene le variabili:

```
lm(y ~ x + x^2, data=df)
```

```

Call:
lm(formula = y ~ x + x^2, data = df)

Coefficients:
(Intercept)            x
      1.908        3.008
```

Osserviamo che la funzione `lm()` ha calcolato solo i coefficienti per l'intercetta e per x, ma non per x^2. Questo perché all'interno di una formula gli operatori `^`, `*` e `:` **non** hanno il loro significato aritmetico, ma servono a indicare le *interazioni* tra più variabili (come vedremo più avanti con i modelli a più variabili). In particolare, `(x + z)^2` in una formula significa "tutti i termini `x` e `z` e la loro interazione `x:z`", e quindi `x^2` per una singola variabile si riduce semplicemente a `x`.

Per **proteggere** dall'espansione di x^2 come formula, dobbiamo racchiudere l'espressione tra parentesi e precederla con la funzione `I()` (identity). Proviamo un modello di grado maggiore del necessario, fino a x^4:

```
df.lm <- lm(y~x + I(x^2) + I(x^3) + I(x^4), data=df)
coef(df.lm)
```

```
  (Intercept)             x        I(x^2)        I(x^3)        I(x^4)
 0.8326865737  2.0211928898  0.1186638267 -0.0048121358  0.0002640569
```

```
summary(df.lm)
```

```

Call:
lm(formula = y ~ x + I(x^2) + I(x^3) + I(x^4), data = df)
```

```
Residuals:
   Min     1Q Median     3Q    Max
-4.344 -1.206 -0.056  1.162  4.928

Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept)  0.8326866  0.3478351   2.394   0.0186 *
x            2.0211929  0.1070973  18.872  < 2e-16 ***
I(x^2)       0.1186638  0.0227324   5.220 1.05e-06 ***
I(x^3)      -0.0048121  0.0045966  -1.047   0.2978
I(x^4)       0.0002641  0.0002227   1.185   0.2388
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.764 on 95 degrees of freedom
Multiple R-squared:  0.9908,    Adjusted R-squared:  0.9904
F-statistic:  2560 on 4 and 95 DF,  p-value: < 2.2e-16
```

La funzione `coef()` restituisce i parametri stimati, mentre `summary()` riporta per ogni parametro anche l'errore standard e il p-value di un test di Student la cui ipotesi nulla è che il parametro sia **nullo**. I termini `I(x^3)` e `I(x^4)` hanno p-value elevati: non sono significativi e vanno rimossi dal modello, che si riduce quindi al secondo grado. In fondo al sommario troviamo anche il coefficiente di determinazione R^2, che indica la frazione della varianza di y spiegata dal modello.

Una forma più breve per scrivere il modello polinomiale è usare la funzione `poly()`, che genera tutti i termini fino al grado indicato:

```r
df.lm <- lm(y~poly(x, 2), data=df)
coef(df.lm)
```

```
(Intercept) poly(x, 2)1 poly(x, 2)2
   16.94601   175.39224    33.20177
```

```r
summary(df.lm)
```

```
Call:
lm(formula = y ~ poly(x, 2), data = df)

Residuals:
    Min      1Q  Median      3Q     Max
-4.2214 -1.1822 -0.1493  1.2671  5.1431
```

```
Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)   16.946      0.176   96.27   <2e-16 ***
poly(x, 2)1  175.392      1.760   99.64   <2e-16 ***
poly(x, 2)2   33.202      1.760   18.86   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.76 on 97 degrees of freedom
Multiple R-squared:  0.9907,    Adjusted R-squared:  0.9905
F-statistic:  5142 on 2 and 97 DF,  p-value: < 2.2e-16
```

I coefficienti però non corrispondono ai valori nominali $a = 1$, $b = 2$, $c = 0.1$! Questo perché per default `poly()` usa dei polinomi **ortogonali**, e non i polinomi **grezzi** (*raw*) $x, x^2, ...$:

- i polinomi **grezzi** si ottengono con `poly(x, 2, raw=TRUE)`, che è equivalente a `x + I(x^2)`. I coefficienti stimati corrispondono direttamente ai parametri a, b, c del modello, ma i termini $x, x^2, x^3, ...$ sono fortemente **correlati** tra loro: aggiungendo o togliendo un termine cambiano in generale le stime degli altri coefficienti, e per gradi elevati il calcolo diventa numericamente instabile;
- i polinomi **ortogonali** sono combinazioni lineari di $x, x^2, ...$ costruite in modo da essere tra loro non correlati sui valori di x osservati. I coefficienti non hanno un'interpretazione fisica diretta, ma sono indipendenti tra loro: aggiungendo un grado al modello, le stime dei coefficienti di grado inferiore **non cambiano**, e il calcolo è numericamente stabile.

Verifichiamolo confrontando i coefficienti dei modelli di grado 2 e 3, nelle due versioni:

```r
# polinomi ortogonali: i primi tre coefficienti restano invariati
cat("Polinomi ortogonali:")
```

```
Polinomi ortogonali:
```

```r
lm(y~poly(x, 2), data=df) %>% coef()
```

```
(Intercept) poly(x, 2)1 poly(x, 2)2
   16.94601    175.39224     33.20177
```

```r
lm(y~poly(x, 3), data=df) %>% coef()
```

```
(Intercept) poly(x, 3)1 poly(x, 3)2 poly(x, 3)3
 16.9460103 175.3922404  33.2017746   0.7302588
```

```r
# polinomi grezzi: i coefficienti cambiano
cat("\nPolinomi grezzi:")
```

```
Polinomi grezzi:
```

```r
lm(y~poly(x, 2, raw=TRUE), data=df) %>% coef()
```

```
            (Intercept) poly(x, 2, raw = TRUE)1
              0.9244438               1.9159210
poly(x, 2, raw = TRUE)2
              0.1091733
```

```r
lm(y~poly(x, 3, raw=TRUE), data=df) %>% coef()
```

```
            (Intercept) poly(x, 3, raw = TRUE)1
           1.0093426310            1.9223914047
poly(x, 3, raw = TRUE)2 poly(x, 3, raw = TRUE)3
           0.1021382819            0.0004690029
```

Con i polinomi grezzi, aggiungendo il termine di terzo grado cambia la stima del coefficiente di x. In questo caso particolare intercetta e coefficiente di x^2 restano invariati solo perché i valori di x sono simmetrici rispetto allo zero, e quindi i termini di grado pari sono non correlati con quelli di grado dispari; con valori di x qualsiasi (ad esempio tra 0 e 20) cambierebbero tutti i coefficienti.

In ogni caso, i due modelli dello stesso grado sono **equivalenti**: forniscono esattamente le stesse previsioni e gli stessi residui, e differiscono solo per il modo in cui sono espressi i coefficienti. Possiamo verificarlo confrontando i valori previsti dai due modelli di grado 2 usando:

- `fitted()`, che restituisce i valori previsti dal modello per ciascun valore di x osservato;
- `all.equal()`, che confronta due oggetti e restituisce `TRUE` se sono uguali (entro una tolleranza numerica):

```r
all.equal(
  fitted(lm(y~poly(x, 2), data=df)),
  fitted(lm(y~poly(x, 2, raw=TRUE), data=df))
)
```

```
[1] TRUE
```

I polinomi ortogonali sono anche più robusti nell'analisi di **significatività** dei parametri, cioè quando si usano i p-value del sommario per decidere quali termini mantenere nel modello. Il motivo è la **correlazione** tra i termini: verifichiamo con `cor()` la matrice di correlazione dei primi quattro termini nelle due versioni:

```
# polinomi grezzi: x e x^3, così come x^2 e x^4, sono fortemente correlati
cor(poly(df$x, 4, raw=TRUE)) %>% round(3)
```

```
      1     2     3     4
1 1.000 0.887 0.855 0.786
2 0.887 1.000 0.985 0.958
3 0.855 0.985 1.000 0.990
4 0.786 0.958 0.990 1.000
```

```
# polinomi ortogonali: la matrice di correlazione è la matrice identità
cor(poly(df$x, 4)) %>% round(3)
```

```
  1 2 3 4
1 1 0 0 0
2 0 1 0 0
3 0 0 1 0
4 0 0 0 1
```

Quando due predittori sono fortemente correlati (si parla di **multicollinearità**), il modello fatica a distinguere il contributo dell'uno da quello dell'altro: le stime dei relativi coefficienti diventano molto incerte, cioè i loro errori standard crescono, e di conseguenza crescono anche i p-value. Un termine realmente significativo può quindi *sembrare* non significativo solo perché nel modello ci sono altri termini correlati con esso.

Confrontiamo i sommari dei modelli di grado 2 (quello corretto) e di grado 7 (sovradimensionato), nelle due versioni:

```
# polinomi ortogonali: stime ed errori standard dei primi termini
# restano praticamente invariati
cat("Polinomi ortogonali:")
```

```
Polinomi ortogonali:
```

```
lm(y~poly(x, 2), data=df) %>% summary()
```

```
Call:
lm(formula = y ~ poly(x, 2), data = df)

Residuals:
    Min      1Q  Median      3Q     Max
-4.2214 -1.1822 -0.1493  1.2671  5.1431

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)   16.946      0.176   96.27   <2e-16 ***
poly(x, 2)1  175.392      1.760   99.64   <2e-16 ***
poly(x, 2)2   33.202      1.760   18.86   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.76 on 97 degrees of freedom
Multiple R-squared:  0.9907,    Adjusted R-squared:  0.9905
F-statistic:  5142 on 2 and 97 DF,  p-value: < 2.2e-16
```

```r
lm(y~poly(x, 7), data=df) %>% summary()
```

```
Call:
lm(formula = y ~ poly(x, 7), data = df)

Residuals:
    Min      1Q  Median      3Q     Max
-3.9553 -1.2232 -0.0623  1.1339  5.1798

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)  16.9460     0.1768  95.825   <2e-16 ***
poly(x, 7)1 175.3922     1.7684  99.179   <2e-16 ***
poly(x, 7)2  33.2018     1.7684  18.775   <2e-16 ***
poly(x, 7)3   0.7303     1.7684   0.413    0.681
poly(x, 7)4   2.0912     1.7684   1.183    0.240
poly(x, 7)5  -2.2585     1.7684  -1.277    0.205
poly(x, 7)6   1.2895     1.7684   0.729    0.468
poly(x, 7)7   1.0684     1.7684   0.604    0.547
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.768 on 92 degrees of freedom
Multiple R-squared:  0.9911,    Adjusted R-squared:  0.9904
F-statistic:  1456 on 7 and 92 DF,  p-value: < 2.2e-16
```

```r
# polinomi grezzi: aggiungendo termini, le stime cambiano e gli errori
# standard dei primi termini crescono
cat("\nPolinomi grezzi:")
```

```
Polinomi grezzi:
```

```r
lm(y~poly(x, 2, raw=TRUE), data=df) %>% summary()
```

```
Call:
lm(formula = y ~ poly(x, 2, raw = TRUE), data = df)

Residuals:
    Min      1Q  Median      3Q     Max
-4.2214 -1.1822 -0.1493  1.2671  5.1431

Coefficients:
                      Estimate Std. Error t value Pr(>|t|)
(Intercept)           0.924444   0.237648    3.89 0.000184 ***
poly(x, 2, raw = TRUE)1 1.915921   0.065276   29.35  < 2e-16 ***
poly(x, 2, raw = TRUE)2 0.109173   0.005788   18.86  < 2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.76 on 97 degrees of freedom
Multiple R-squared:  0.9907,    Adjusted R-squared:  0.9905
F-statistic:  5142 on 2 and 97 DF,  p-value: < 2.2e-16
```

```r
lm(y~poly(x, 7, raw=TRUE), data=df) %>% summary()
```

```
Call:
lm(formula = y ~ poly(x, 7, raw = TRUE), data = df)

Residuals:
    Min      1Q  Median      3Q     Max
-3.9553 -1.2232 -0.0623  1.1339  5.1798

Coefficients:
                        Estimate Std. Error t value Pr(>|t|)
(Intercept)            9.709e-01  4.357e-01   2.228   0.0283 *
poly(x, 7, raw = TRUE)1  2.290e+00  2.190e-01  10.459   <2e-16 ***
poly(x, 7, raw = TRUE)2  7.738e-02  7.964e-02   0.972   0.3338
poly(x, 7, raw = TRUE)3 -2.286e-02  2.160e-02  -1.058   0.2928
```

```
poly(x, 7, raw = TRUE)4  2.897e-03  2.385e-03   1.215   0.2274
poly(x, 7, raw = TRUE)5  1.286e-04  6.754e-04   0.190   0.8494
poly(x, 7, raw = TRUE)6 -3.010e-05  6.096e-05  -0.494   0.6226
poly(x, 7, raw = TRUE)7  1.041e-06  1.724e-06   0.604   0.5472
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.768 on 92 degrees of freedom
Multiple R-squared:  0.9911,    Adjusted R-squared:  0.9904
F-statistic:  1456 on 7 and 92 DF,  p-value: < 2.2e-16
```

Osserviamo che:

- con i polinomi **ortogonali**, i termini di primo e secondo grado hanno la stessa stima e praticamente lo stesso errore standard in entrambi i modelli, e restano nettamente significativi; tutti i termini dal terzo grado in su hanno invece p-value elevati. Il sommario del modello di grado 7 indica quindi in modo univoco che il modello corretto è di secondo grado;
- con i polinomi **grezzi**, nel modello di grado 7 l'errore standard del coefficiente di x^2 è circa 8 volte più grande che nel modello di grado 2, e il suo p-value passa da un valore praticamente nullo a circa 0.01. Con un livello di significatività più severo (ad esempio 1%) concluderemmo erroneamente che il termine quadratico non è significativo, e se rimuovessimo i termini uno alla volta il risultato dipenderebbe dall'ordine in cui lo facciamo;
- il p-value del termine di grado **massimo** è invece lo stesso nelle due versioni: è l'unico termine che le due basi polinomiali rappresentano allo stesso modo, cioè come il contributo aggiuntivo rispetto a tutti i termini di grado inferiore.

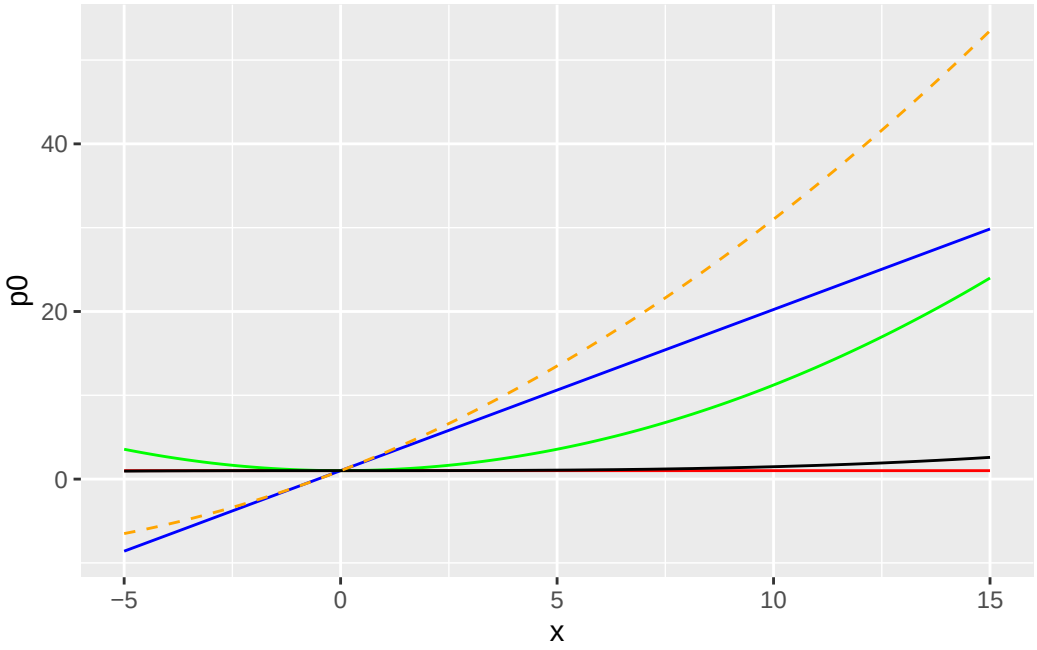
Per questo motivo, per decidere quale grado del polinomio sia necessario conviene stimare un modello sovradimensionato con polinomi ortogonali, individuare il grado massimo significativo e infine, se servono i valori fisici dei coefficienti, stimare il modello ridotto con polinomi grezzi.

> **Consiglio**
>
> In pratica, si usano i polinomi grezzi quando interessano i valori dei coefficienti, e quelli ortogonali quando interessa solo il modello (ad esempio per fare previsioni) o per gradi elevati, e per analizzare la significatività (p-value) dei vari contributi.

Graficamente, per un polinomio grezzo:

```r
df.lm <- lm(y~poly(x, 3, raw=T), data=df)
df.c <- coef(df.lm)
df %>% mutate(
  p0 = df.c[1],
  p1 = df.c[2] * x,
```

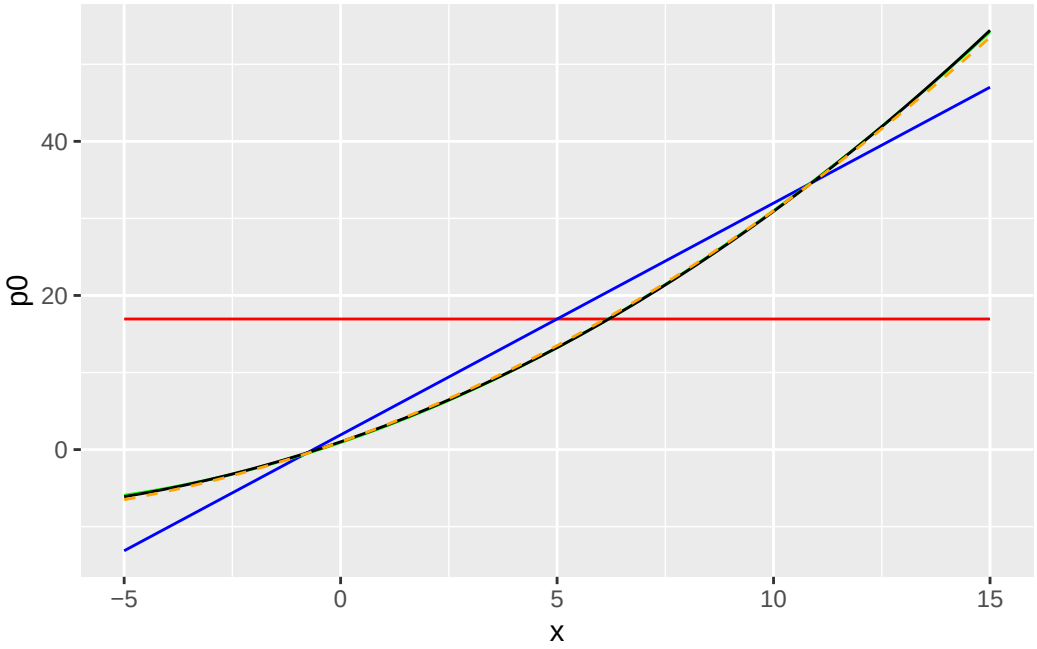
```
  p2 = df.c[3] * x^2,
  p3 = df.c[4] * x^3
) %>%
  ggplot(aes(x=x)) +
  geom_line(aes(y=p0), color="red") +
  geom_line(aes(y=p0+p1), color="blue") +
  geom_line(aes(y=p0+p2), color="green") +
  geom_line(aes(y=p0+p3), color="black") +
  geom_line(aes(y=y_nom), color="orange", lty=2)
```



Invece, per un polinomio ortogonale ogni contributo è $\beta_k P_k(x)$, dove P_k è il polinomio ortogonale di grado k e β_k il coefficiente stimato. La somma dei contributi fino al grado k fornisce la stima del modello di grado k:

```
df.lmo <- lm(y~poly(x, 3), data=df)
df.co <- coef(df.lmo)
P <- poly(df$x, 3)   # same basis used inside lm (same x values)
df %>% mutate(
  p0 = df.co[1],
  p1 = df.co[2] * P[,1],
  p2 = df.co[3] * P[,2],
  p3 = df.co[4] * P[,3]
) %>%
  ggplot(aes(x=x)) +
  geom_line(aes(y=p0), color="red") +
```

```
  geom_line(aes(y=p0+p1), color="blue") +
  geom_line(aes(y=p0+p1+p2), color="green") +
  geom_line(aes(y=p0+p1+p2+p3), color="black") +
  geom_line(aes(y=y_nom), color="orange", lty=2)
```



Si noti che ogni componente rappresenta **esattamente** la regressione dei dati fino al grado corrispondente.

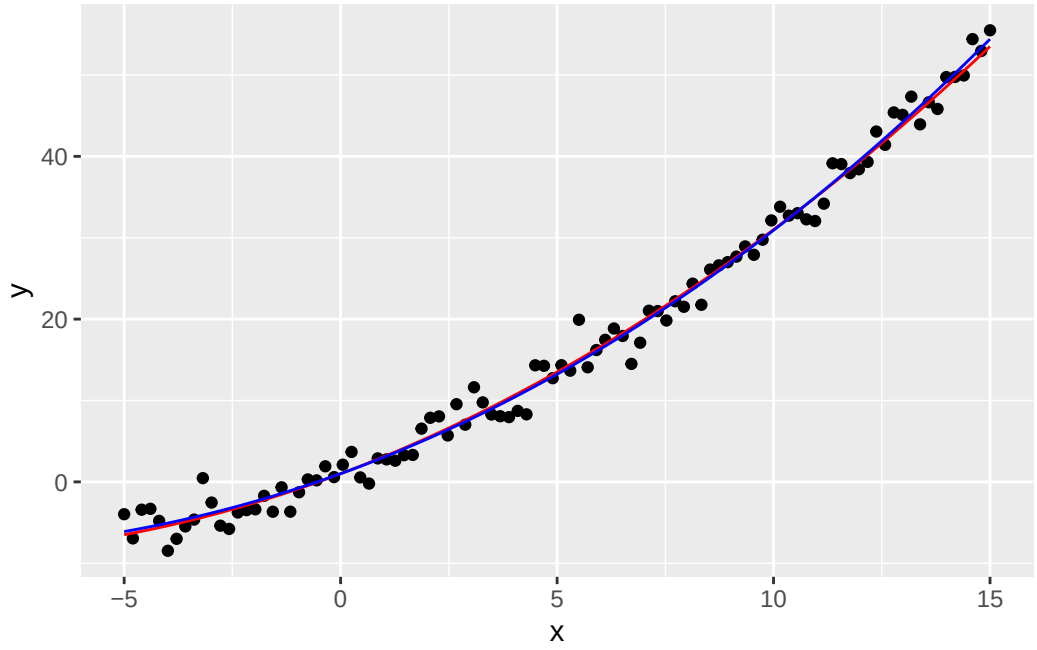
> **Esercizio**
>
> Ripetere gli ultimidue grafici trasformando la tabella in forma *tidy* e usando un'unica geometria `geom_line()` con l'estetica `color` mappata sulla colonna che indica il grado del polinomio. Aggiungere anche i punti dei dati osservati.

Il prossimo passo è utilizzare il modello per predire i valori di y e verificare la normalità dei residui. Le funzioni `add_predictions()` e `add_residuals()` (della libreria `adas.utils`) aggiungono a una tabella rispettivamente la colonna `pred` con i valori previsti dal modello e la colonna `resid` con i residui, cioè le differenze tra i valori osservati e quelli previsti:

```
df2 <- df %>%
  add_predictions(df.lm) %>%
  add_residuals(df.lm)

# in rosso la relazione nominale, in blu il modello stimato
df2 %>% ggplot(aes(x=x)) +
```

```
  geom_point(aes(y=y)) +
  geom_line(aes(y=y_nom), color="red") +
  geom_line(aes(y=pred), color="blue")
```



Il modello è valido solo se i residui rispettano le ipotesi fatte, cioè se sono distribuiti normalmente (e, come vedremo, se non mostrano andamenti sistematici). Verifichiamo la normalità con il test di Shapiro-Wilk:

```
shapiro.test(df2$resid)
```

```
    Shapiro-Wilk normality test

data:  df2$resid
W = 0.98951, p-value = 0.6248
```

> **Esercizio**
>
> Verificare la normalità dei residui con metodi grafici come il diagramma Q-Q e l'istogramma.

1.2 Estrapolazione

Un modello di regressione è valido solo all'interno dell'intervallo dei dati usati per stimarlo. Usarlo al di fuori di questo intervallo si chiama **estrapolazione**, ed è un'operazione

rischiosa. Per mostrarlo, dividiamo i dati in due sottoinsiemi: quelli interni all'intervallo $(-7.5, 7.5)$ (`in`) e quelli esterni (`out`):

```
df3 <- df %>%
  mutate(
    subset = ifelse(x > -2.5 & x < 13.5, "in", "out")
  )

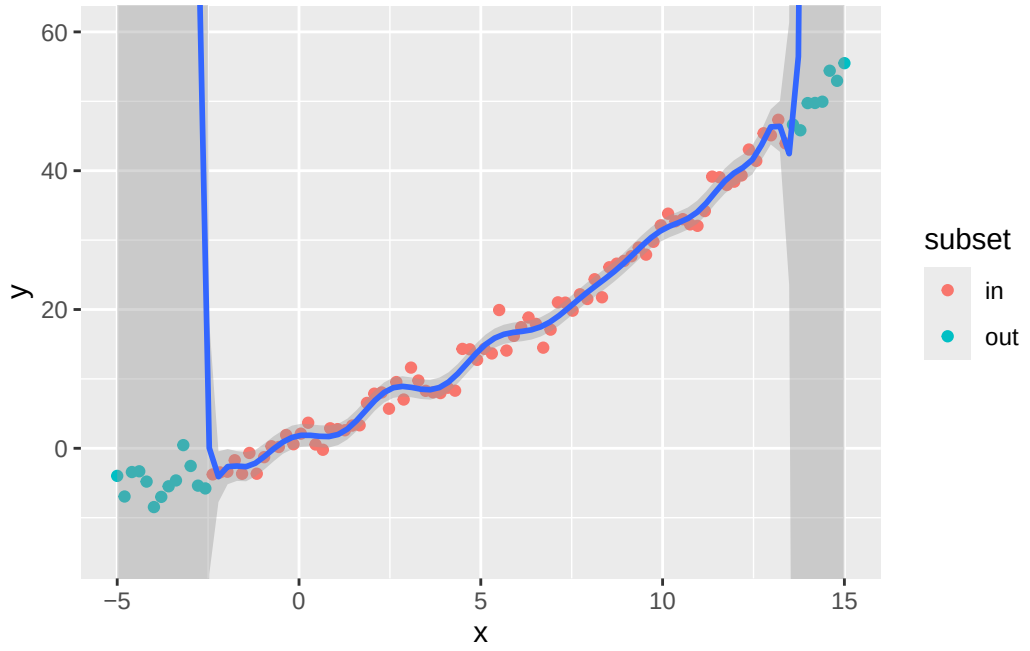
df3 %>%
  ggplot(aes(x=x, y=y, color=subset)) +
  geom_point()
```



Ora stimiamo un modello usando **solo** i dati interni, e lo rappresentiamo su tutto l'intervallo. La funzione `geom_smooth()` stima e disegna direttamente un modello di regressione (con `method="lm"`) secondo la formula indicata; l'opzione `fullrange=TRUE` estende la curva a tutto l'intervallo dell'asse x. Volutamente scegliamo un polinomio di grado molto elevato (21):

```
df3 %>%
  ggplot(aes(x=x, y=y)) +
  geom_point(aes(color=subset)) +
  geom_smooth(
    data=filter(df3, subset == "in"),
    method="lm",
    formula= y~poly(x, 21),
    fullrange=TRUE
```

```
  ) +
  coord_cartesian(ylim=c(-15,60))
```



All'interno dell'intervallo il modello segue (anche troppo) fedelmente i dati, inseguendo il rumore casuale: si parla di **sovradattamento** (*overfitting*). Appena fuori dall'intervallo, invece, la curva diverge rapidamente e le previsioni non hanno più alcun senso. La funzione `coord_cartesian()` limita l'area visualizzata senza eliminare dati, altrimenti la curva renderebbe illeggibile il grafico.

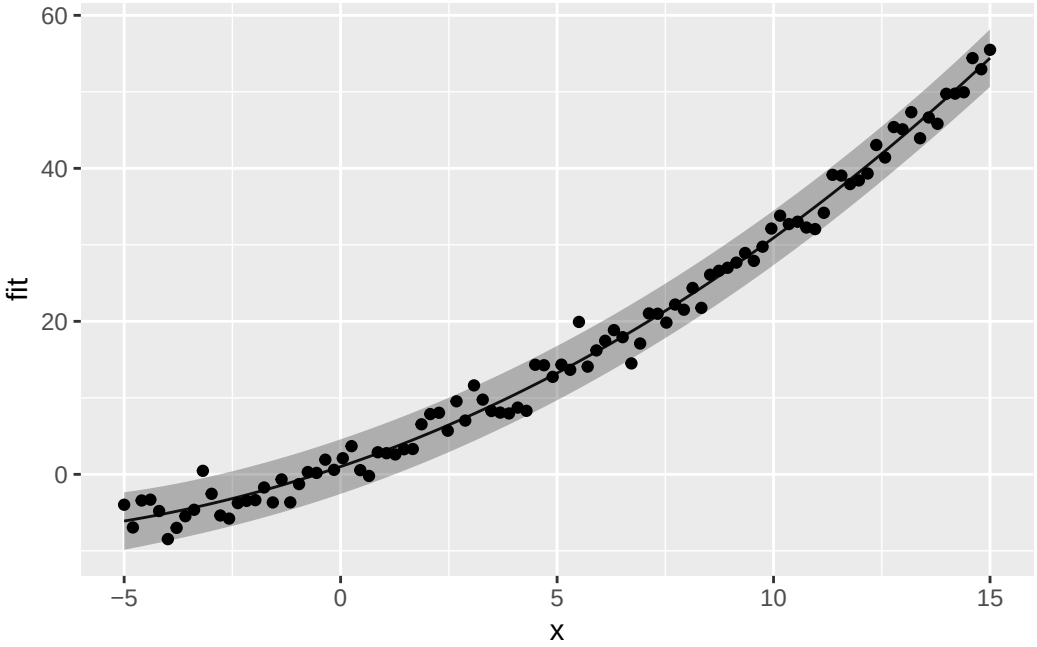
> **Esercizio**
>
> Ripetere il grafico con polinomi di grado 1, 2 e 5 e commentare il risultato.

La geometria `geom_smooth()` è comoda per fare una stima rapida, ma fornisce soltanto un risultato grafico. Per fare previsioni e analizzare i residui, bisogna stimare il modello con `lm()` e poi usare `add_predictions()` e `add_residuals()` come visto sopra.

Con l'opzione `interval="prediction"`, la funzione `add_predictions()` aggiunge le colonne `fit` (valore previsto), `lwr` e `upr` (limiti inferiore e superiore dell'**intervallo di predizione**, al 95% per default). L'intervallo di predizione è la banda entro cui ci aspettiamo che cada una **nuova osservazione** di y, per un dato x:

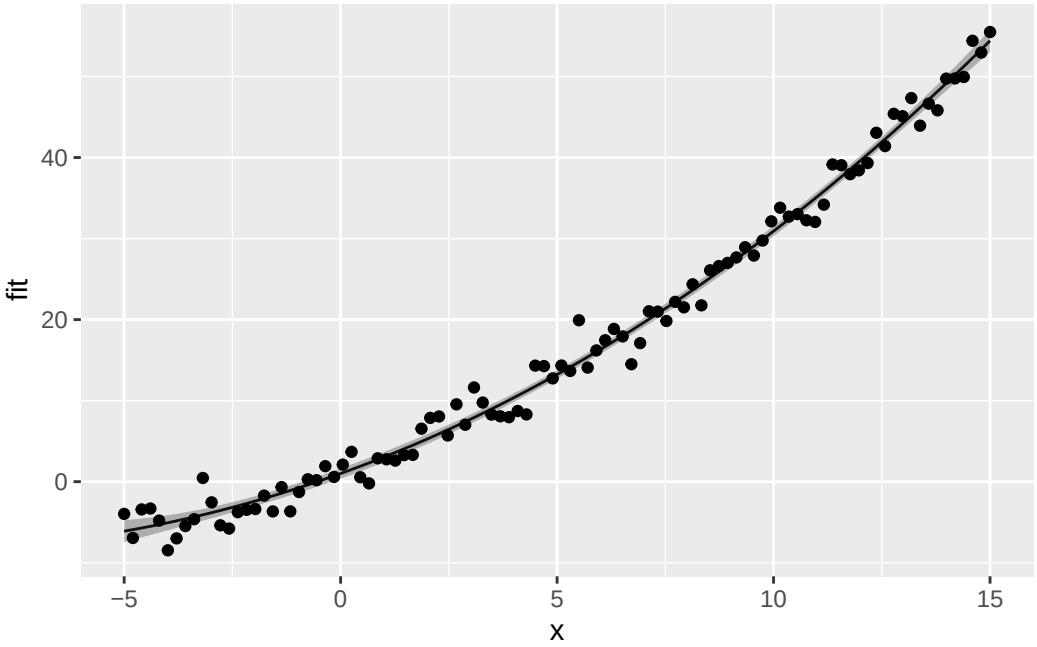
```
df %>%
  add_predictions(df.lm, interval="prediction") %>%
  ggplot(aes(x=x)) +
  geom_line(aes(y=fit)) +
```

```
  geom_ribbon(aes(ymin=lwr, ymax=upr), alpha=1/3) +
  geom_point(aes(y=y))
```



Con `interval="confidence"` si ottiene invece l'**intervallo di confidenza**, cioè la banda entro cui si trova, con il 95% di probabilità, il **valore atteso** di y (la curva vera). L'intervallo di confidenza è sempre più stretto di quello di predizione, perché quest'ultimo tiene conto anche della dispersione σ delle singole osservazioni:

```
df %>%
  add_predictions(df.lm, interval="confidence") %>%
  ggplot(aes(x=x)) +
  geom_line(aes(y=fit)) +
  geom_ribbon(aes(ymin=lwr, ymax=upr), alpha=1/3) +
  geom_point(aes(y=y))
```



1.3 Regressione ai minimi quadrati

Non tutti i modelli possono essere espressi come modelli lineari nei parametri. Consideriamo ad esempio un **problema di contatto**: misuriamo la forza tra due corpi (es. sfera e piano) inizialmente separati mentre si avvicinano, e registriamo la forza f in funzione della posizione y. Si tratta di una funzione che vale costantemente `bias` fino a y_0, e da y_0 in poi prosegue come una parabola con vertice in (y_0, bias) e coefficiente quadratico a:

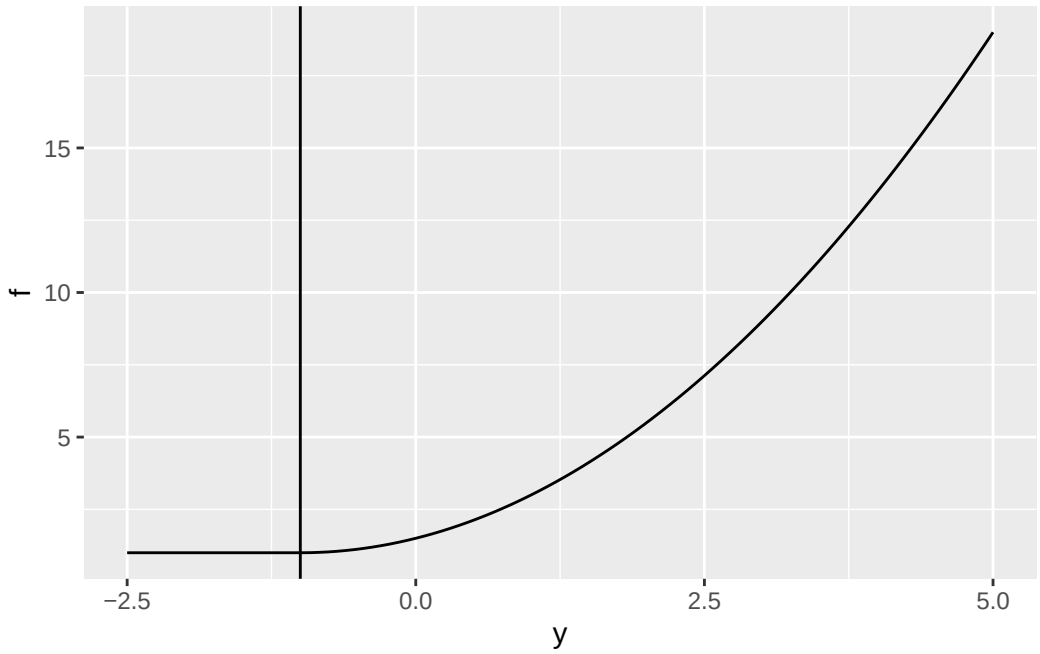
$$f(y) = \begin{cases} \text{bias} & y < y_0 \\ \text{bias} + a(y - y_0)^2 & y \geq y_0 \end{cases}$$

Il parametro y_0 compare in modo non lineare (e anche all'interno di una condizione), quindi `lm()` non è utilizzabile. Definiamo la funzione in R, sviluppando il quadrato nei coefficienti b e c della parabola, e rappresentiamola:

```
f <- function(y, y0=0, bias=0, a=1) {
  b <- -2 *a *y0
  c <- bias + a * y0^2
  f <- a * y^2 + b * y + c
  # ifelse() è la versione vettorializzata di if-else
  return(ifelse(y<y0, bias, f))
}

tibble(
```

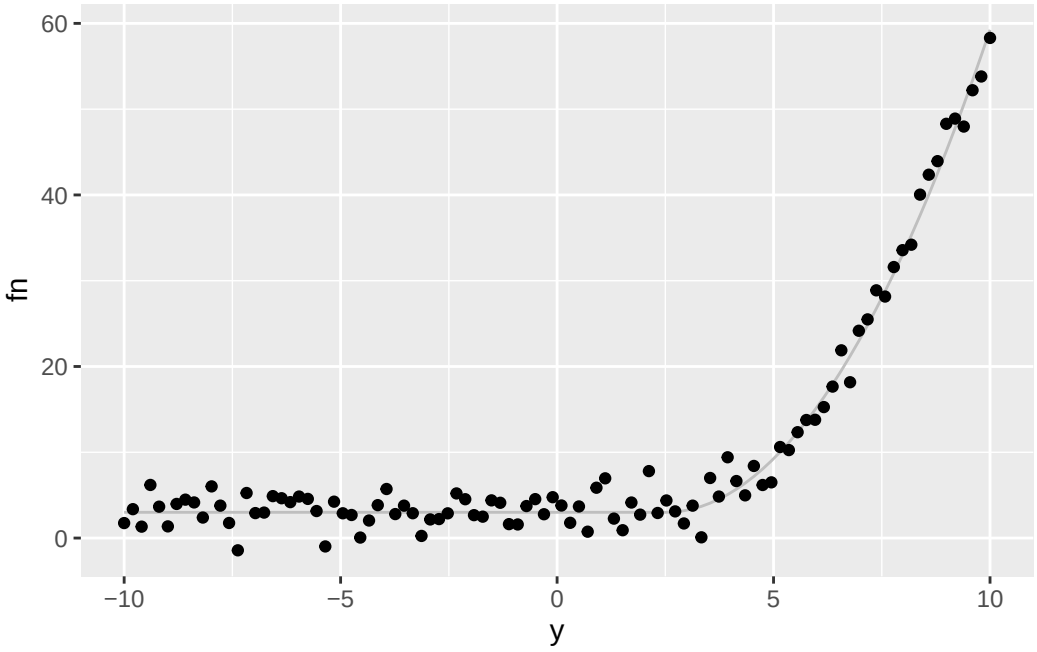
```
  y = seq(-2.5, 5, length.out=100),
  f = f(y, -1, 1, 0.5)
) %>%
  ggplot(aes(x=y, y=f)) +
  geom_line() +
  geom_vline(xintercept=-1)
```



Generiamo ora dei dati sintetici con $y_0 = 2.5$, bias $= 3$ e $a = 1$, aggiungendo un disturbo normale:

```
set.seed(1)
df <- tibble(
  y = seq(-10, 10, length.out=100),
  fn = f(y, 2.5, 3, 1),
  f = fn + rnorm(length(y), 0, 2)
)

df %>% ggplot(aes(x=y)) +
  geom_line(aes(y=fn), color=grey(3/4)) +
  geom_point(aes(y=f))
```



Si noti che dai soli dati è molto difficile individuare il punto di contatto y_0, perché la parabola è molto piatta vicino al minimo. Tale valore può però essere **identificato** mediante una regressione non lineare, che stima i parametri y_0, bias e a a partire dai dati osservati.

Il metodo dei **minimi quadrati** consiste nel cercare i valori dei parametri che rendono minima la somma dei quadrati dei residui:

$$\Phi(y_0, \text{bias}, a) = \sum_{i=1}^{N} (f_i - f(y_i; y_0, \text{bias}, a))^2$$

Per i modelli lineari il minimo si ottiene analiticamente (ed è proprio ciò che fa `lm()`); nel caso generale bisogna invece cercarlo **numericamente**. Definiamo la funzione obiettivo Z, che prende come primo argomento il vettore dei parametri, e la minimizziamo con la funzione `optim()`, partendo da una stima iniziale dei parametri:

```
Phi <- function(par, data) {
  sum((data$f - f(data$y, par["y0"], par["bias"], par["a"]))^2)
}

fit <- optim(c(y0=0, bias=0, a=1), Phi, data=df)
fit$par         # parametri stimati
```

```
      y0     bias        a
2.505737 3.258401 0.996786
```

```r
fit$convergence # 0 indica che l'ottimizzazione è andata a buon fine
```

```
[1] 0
```

R mette anche a disposizione la funzione `nls()` (*non-linear least squares*), che usa una formula come `lm()`. A destra della `~` si scrive l'espressione del modello, indicando i parametri per nome, e con l'argomento `start` si forniscono i valori iniziali dei parametri da stimare. Rispetto a `optim()`, `nls()` fornisce anche gli errori standard e i p-value dei parametri:

```r
# NB: a sinistra della ~ c'è la colonna f, a destra la funzione f()
df.nls <- nls(f ~ f(y, y0, bias, a), data=df, start=list(y0=0, bias=0,
 ↪  a=1))
summary(df.nls)
```

```
Formula: f ~ f(y, y0, bias, a)

Parameters:
     Estimate Std. Error t value Pr(>|t|)
y0    2.50571    0.14758   16.98   <2e-16 ***
bias  3.25779    0.22222   14.66   <2e-16 ***
a     0.99672    0.04765   20.92   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 1.813 on 97 degrees of freedom

Number of iterations to convergence: 5
Achieved convergence tolerance: 1.91e-06
```

! Dov'è R^2?

Per la regressione non lineare non esiste un equivalente del coefficiente di determinazione R^2 dei modelli lineari. In altre parole, per una regressione non lineare si possono avere valori di R^2 negativi, oppure regressioni palesemente errate con valori di R^2 molto vicini a 1. Per questo motivo, per valutare la bontà del modello conviene sempre rappresentare graficamente i dati osservati e quelli previsti dal modello, e verificare la normalità dei residui.
Per confrontare regressioni ottenute con differenti modelli non lineari è possibile usare il criterio di informazione di Akaike (AIC), che tiene conto sia della bontà del modello che del numero di parametri stimati. **Più basso è il valore di AIC, migliore è il modello**. In R si calcola con la funzione `AIC()`:

```
AIC(df.nls)
```

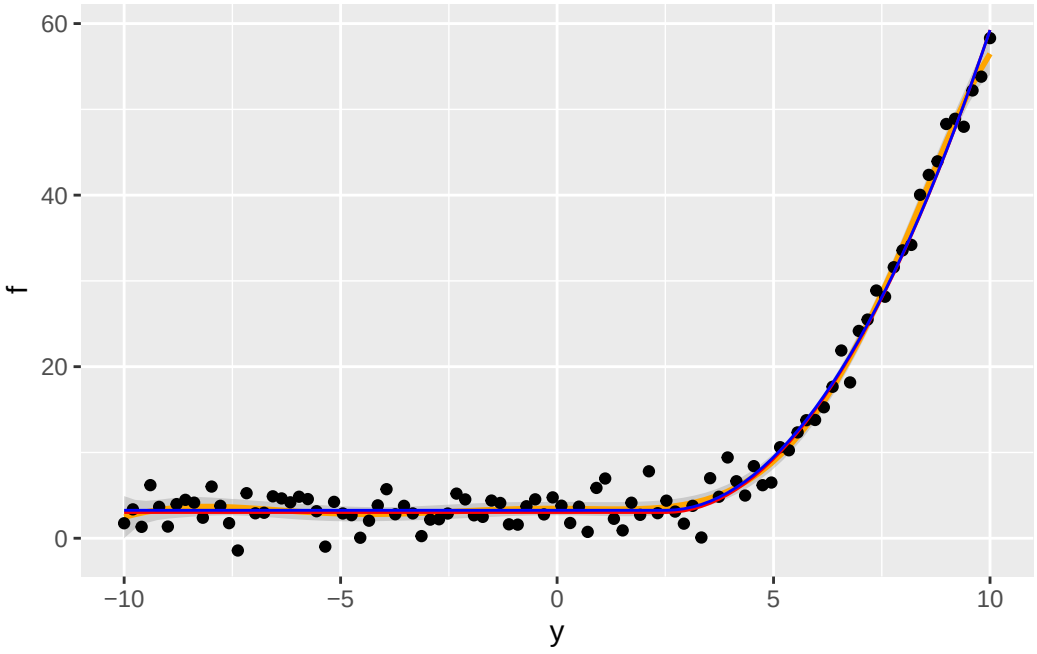
```
[1] 407.7792
```

```
AIC(lm(f~poly(y, 7), data=df))
```

```
[1] 409.8989
```

Il modello stimato si usa come quelli lineari, ad esempio per aggiungere previsioni e residui alla tabella:

```
df %>%
  add_predictions(df.nls) %>%
  ggplot(aes(x=y)) +
  geom_smooth(
    aes(y=f), color="orange", method="lm", formula=y~poly(x, 7)) +
  geom_point(aes(y=f)) +
  geom_line(aes(y=fn), color="red") +
  geom_line(aes(y=pred), color="blue")
```



Si noti che abbiamo aggiunto anche la stima di un modello lineare di grado 7, per mostrare che il modello non lineare stimato con `nls()` segue meglio i dati osservati, giustificando i valori di AIC più bassi sopra riportati.

> **Avviso**
>
> Gli algoritmi di ottimizzazione numerica sono **iterativi** e partono dai valori iniziali forniti: se questi sono troppo lontani dalla soluzione, l'algoritmo può non convergere o convergere a un minimo locale. È quindi buona norma scegliere valori iniziali ragionevoli (ad esempio stimandoli dal grafico dei dati) e verificare sempre il risultato graficamente.

> **Esercizio**
>
> Verificare la normalità dei residui del modello `df.nls`, e provare a ripetere la stima con valori iniziali diversi (ad esempio `y0=-5`).

1.4 Regressione lineare generalizzata

Carichiamo la tabella di dati di esempio "soap_bottles.dat". Essa contiene i risultati di un *drop test* su bottiglie di sapone, in cui si verifica la sopravvivenza della bottiglia al variare del livello di riempimento p rispetto alla capacità massima dopo una caduta da 1 m di altezza. La colonna `OK` indica se la bottiglia è sopravvissuta (`TRUE`) o meno (`FALSE`).

Infatti, il polmone d'aria della bottiglia consente di assorbire le onde di sovrapressione generate dall'urto, e quindi la probabilità di sopravvivenza dipende dal livello di riempimento (oltre che dalle specificità aleatorie della singola bottiglia). La relazione tra la probabilità di fallimento e il livello di riempimento è tipicamente **sigmoide**, e può essere modellata con una **regressione logistica**, che tipicamente rappresenta dei processi, come questo, **bimodali**.

Per comodità, Creiamo una nuova colonna `fail` che indica il fallimento del test, e rimuoviamo la colonna `OK`:

```
data <- examples_url("soap_bottles.dat") %>%
  read.table(header=T, comment="#") %>%
  mutate(
    fail = !OK
  ) %>%
  select(-OK)

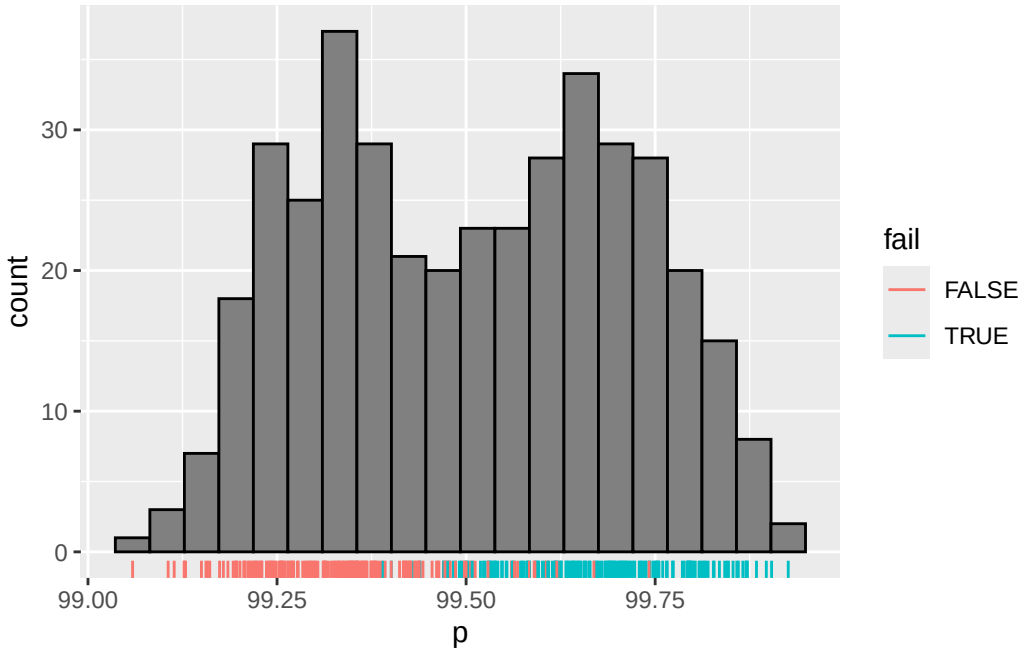
data %>% head()
```

```
  run      p  fail
1   1 99.314 FALSE
2   2 99.357 FALSE
3   3 99.624 FALSE
4   4 99.429  TRUE
```

```
5   5 99.860  TRUE
6   6 99.212 FALSE
```

Osserviamo la distribuzione dei valori di `p` in un istogramma, con un *rug plot* che indica i valori di `p` per le bottiglie che hanno fallito/superato il test:

```
data %>%
  ggplot(aes(x=p)) +
  geom_histogram(bins=20, fill=gray(1/2), color="black") +
  geom_rug(aes(color=fail))
```



Il set di dati è abbastanza sostanzioso:

```
dim(data)
```

```
[1] 400   3
```

Possiamo quindi dividerlo in due parti: un sottoinsieme di **addestramento** (*training set*) per stimare i parametri del modello, e un sottoinsieme di **validazione** (*validation set*) per verificare la bontà del modello stimato. La divisione può essere fatta in modo casuale, ad esempio con una probabilità dell'80% di finire nel sottoinsieme di addestramento e del 20% in quello di validazione.

Per farlo, generiamo una colonna `training` che contiene etichette casuali "train" o "valid" per ciascun record, con probabilità 80% e 20% rispettivamente. La funzione `sample()`

genera un campione casuale di etichette, e l'argomento `replace=TRUE` indica che valore può essere estratto più volte (si dice *campionamento con reinserimento*):

```
sample(c("train", "valid"), size=5, replace=TRUE)
```

```
[1] "valid" "valid" "train" "valid" "valid"
```

Quindi:

```
set.seed(1)
data <- data %>%
  mutate(
    training=sample(c("train", "valid"), size=n(), prob=c(80, 20),
    ↪  replace=TRUE)
  )
```

Per verificare la distribuzione dei dati nei due sottoinsiemi, possiamo contare il numero di record in ciascun sottoinsieme mediante `dplyr::summarise()`:

```
data %>%
  summarise(
    n=n(),
    .by=training
  )
```

```
  training   n
1    train 328
2    valid  72
```

Finalmente possiamo regredire il modello generalizzato, usando come **link function** la funzione logit. In R, la regressione logistica si ottiene con la funzione `glm()` (*generalized linear model*), indicando come argomento `family="binomial"`:

```
data.glm <- glm(fail~p, family="binomial", data=filter(data,
 ↪  training=="train"))

summary(data.glm)
```

```
Call:
glm(formula = fail ~ p, family = "binomial", data = filter(data,
    training == "train"))
```

```
Coefficients:
             Estimate Std. Error z value Pr(>|z|)
(Intercept) -2213.654    260.927  -8.484   <2e-16 ***
p              22.245      2.622   8.484   <2e-16 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 454.51  on 327  degrees of freedom
Residual deviance: 132.28  on 326  degrees of freedom
AIC: 136.28

Number of Fisher Scoring iterations: 7
```

```r
coef(data.glm)
```

```
(Intercept)           p
-2213.65369    22.24533
```

La funzione logit è definita come:

$$\text{logit}(x) = \frac{1}{1 + e^{-(px+m)}}$$

Che è equivalente alla:

$$\text{logit}(x) = \frac{1}{1 + e^{-p(x-x_0)}}$$

dove l'ascissa del punto di flesso x_0 è legata ai coefficienti del modello dalla relazione:

$$x_0 = -m/p$$

Quindi:

```r
p <-  coef(data.glm)[2]
x0 <- -coef(data.glm)[1] / p
x0
```

```
(Intercept)
   99.51093
```

```
p
```

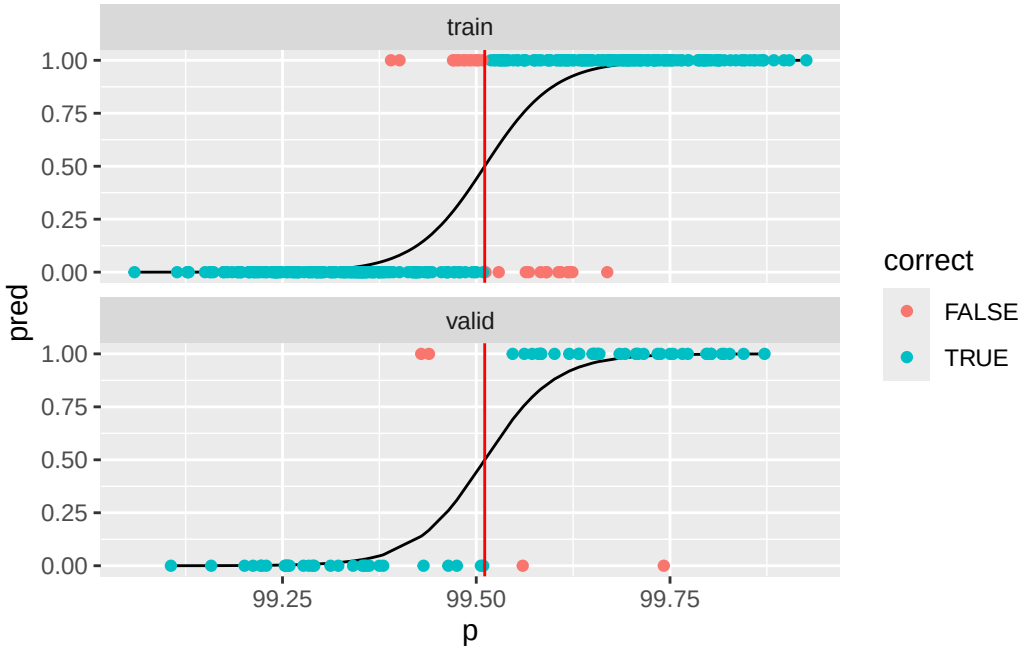
```
       p
22.24533
```

Per visualizzare la regressione aggiungiamo le predizioni alla tabella, specificando `type="response"` per ottenere le probabilità di fallimento (altrimenti si ottengono i valori della funzione logit senza la trasformazione inversa):

```
data <- data %>%
  add_predictions(data.glm, type="response")
```

Possiamo ora mettere in grafico i dati e la curva di regressione, distinguendo i due sottoinsiemi di addestramento e validazione. La linea rossa verticale indica il punto di flesso della curva e separa le due regioni di probabilità di fallimento maggiore o minore del 50%, con gli insiemi dei falsi positivi e dei falsi negativi equipopolati:

```
data %>%
  mutate(
    correct = (fail == (pred > 0.5))
  ) %>%
  ggplot(aes(x=p)) +
  geom_line(aes(y=pred)) +
  geom_point(aes(y=as.numeric(fail), color=correct)) +
  geom_vline(xintercept=x0, color="red") +
  facet_wrap(~training, nrow=2)
```



Si noti l'utilizzo di `facet_wrap()` per creare due grafici separati per i due sottoinsiemi, scegliendo i sottoinsiemi con `~training`, e di `as.numeric()` per convertire i valori booleani in numerici (0/1) in modo da poterli rappresentare sull'asse verticale.

Si osserva che gli errori di classificazione sono equiprobabili anche sull'insieme di validazione (due falsi positivi e due falsi negativi).

In maniera più quantitativa, possiamo contare e confrontare i vari casi:

```
error_type <- function(outcome, pred) {
  if (outcome == pred) return("correct")
  else if (outcome & !pred) return("false neg")
  else if (!outcome & pred) return("false pos")
}

data %>%
  mutate(
    type=map2_chr(fail, pred>0.5, error_type)
  ) %>%
  summarise(
    count=n(),
    .by = c(training, fail, type)
  ) %>%
  arrange(training, fail, type)
```

```
  training  fail      type count
1    train FALSE   correct   155
```

```
2    train FALSE false pos    13
3    train  TRUE   correct   146
4    train  TRUE false neg    14
5    valid FALSE   correct    30
6    valid FALSE false pos     2
7    valid  TRUE   correct    38
8    valid  TRUE false neg     2
```

Esercizio

Calcolare la tabella con le percentuali di falsi positivi e falsi negativi per i due sottoinsiemi.

1.4.1 Soluzione

```
# calcoliamo prima i totali per ciascun sottoinsieme
totals <- data %>% summarise(n=n(), .by=training)

# Per ogni riga aggiungiamo la colonna dei totali
data %>%
  mutate(
    type=map2_chr(fail, pred>0.5, error_type),
    totals=map_int(training, \(x) totals$n[totals$training==x])
  ) %>%
  # calcoliamo il sommario calcolando la frazione percentuale
  summarise(
    count=n(),
    totals=first(totals),
    fraction = (count/first(totals)*100) %>% round(1),
    .by = c(training, fail, type)
  ) %>%
  arrange(training, fail, type) %>%
  knitr::kable()
```

training	fail	type	count	totals	fraction
train	FALSE	correct	155	328	47.3
train	FALSE	false pos	13	328	4.0
train	TRUE	correct	146	328	44.5
train	TRUE	false neg	14	328	4.3
valid	FALSE	correct	30	72	41.7
valid	FALSE	false pos	2	72	2.8
valid	TRUE	correct	38	72	52.8
valid	TRUE	false neg	2	72	2.8

Provare a cambiare la soglia di classificazione da 0.5 a 0.4 e a 0.6, e osservare come cambiano le percentuali di falsi positivi e falsi negativi.